# Иерархия памяти СUDA. Текстуры в СUDA. Цифровая обработка сигналов

**Ж**Лекторы:

**№** Боресков А.В. (ВМиК МГУ)

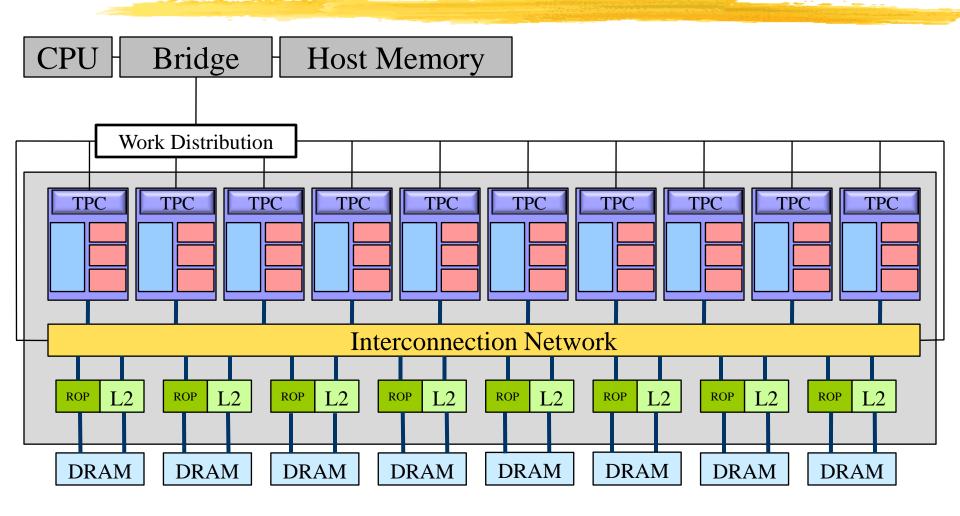
#### Типы памяти в CUDA

Тип памяти	Доступ	Уровень выделения	Скорость работы
Регистры	R/W	Per-thread	Высокая(on-chip)
Локальная	R/W	Per-thread	Низкая (DRAM)
Shared	R/W	Per-block	Высокая(on-chip)
Глобальная	R/W	Per-grid	Низкая (DRAM)
Constant	R/O	Per-grid	Высокая(L1 cache)
Texture	R/O	Per-grid	[-] Низкая(DRAM) [+] L1 cache

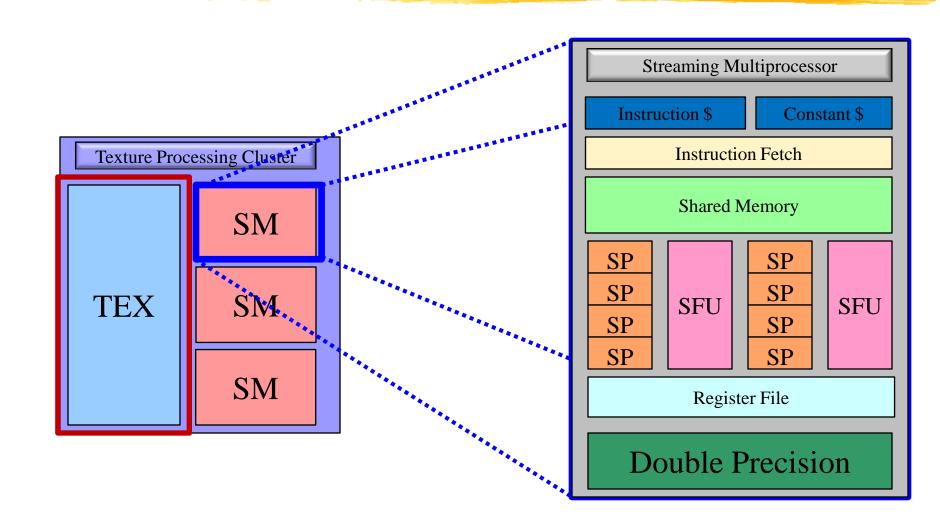
# Архитектура

**#**Сегодня мы рассмотрим Texture Unit

# Архитектура Tesla 10

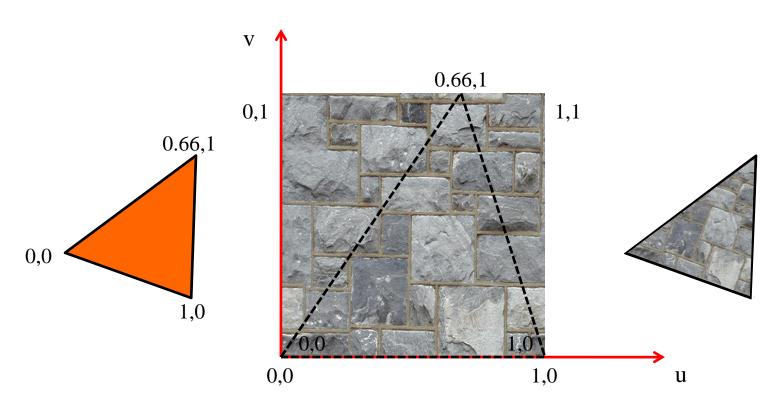


# Архитектура Tesla Мультипроцессор Tesla 10



#### **Texture в 3D**

# В CUDA есть доступ к fixed-function HW: Texture Unit



### **Texture HW**

- **Ж** Латентность больше, чем у прямого обращения в память
  - △Дополнительные стадии в конвеере:

    - **Ж**Фильтрация
- **Ж** Но зато есть кэш
  - № Разумно использовать, если:

    - Паттерн доступа хаотичный
    - Данные переиспользуются разными потоками

# Texture в CUDA (cudaArray)

- **\*\***Особый контейнер памяти: cudaArray
- **Ж**Черный ящик для приложения
- - № 1/2/4 компонентные векторы
  - △8/16/32 bit signed/unsigned integers
  - △32 bit float
  - △16 bit float (driver API)

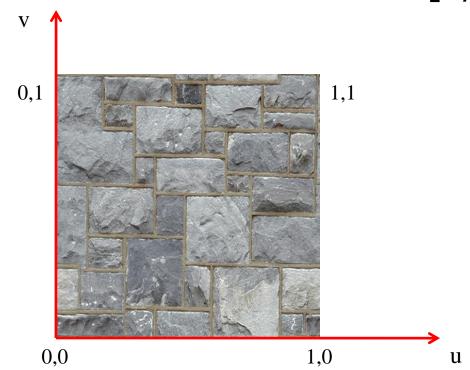
# Texture в CUDA (cudaArray)

- **ЖОсобенности текстур:** 
  - Обращение к 1D / 2D / 3D массивам данных по:
    - Целочисленным индексам
    - Нормализованным координатам
  - □Преобразование адресов на границах
    - **∠** Clamp
    - **⊠**Wrap
  - - **Point**
    - **Linear**
  - □Преобразование данных

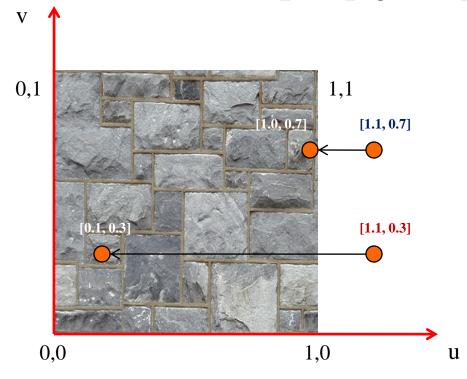
    - ⊠Возвращаемое значение − float4

#### **Ж**Нормализация координат:

Обращение по координатам, которые лежат в диапазоне [0,1]



#### **Ж**Преобразование координат:

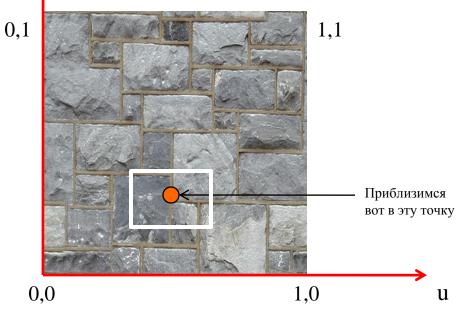


#### Clamp:

-Координата «обрубается» по допустимым границам Wrap

- Координата «заворачивается» в допустимый диапозон

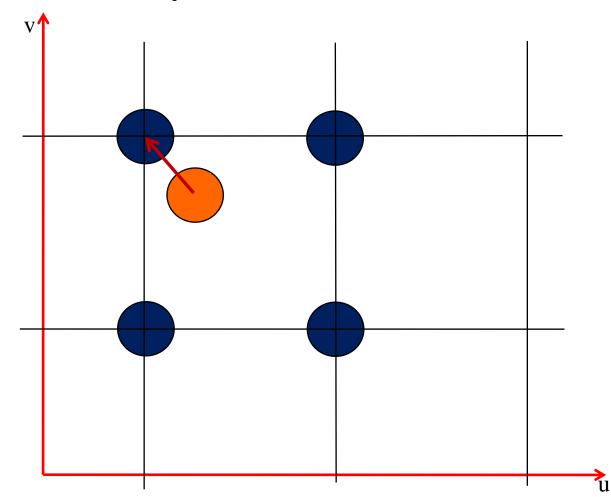
#### ₩Фильтрация:



#### Point:

- -Берется ближайший texel Linear:
- Билинейная фильтрация

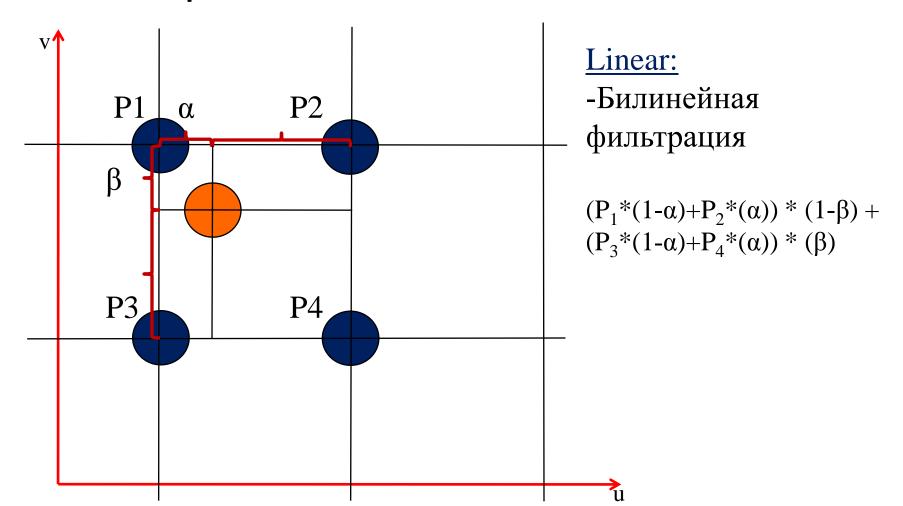
# #Фильтрация



#### **Point:**

-Берется ближайший texel

### **ж**Фильтрация



#### **Ж**Преобразование данных:

#### cudaReadModeNormalizedFloat :

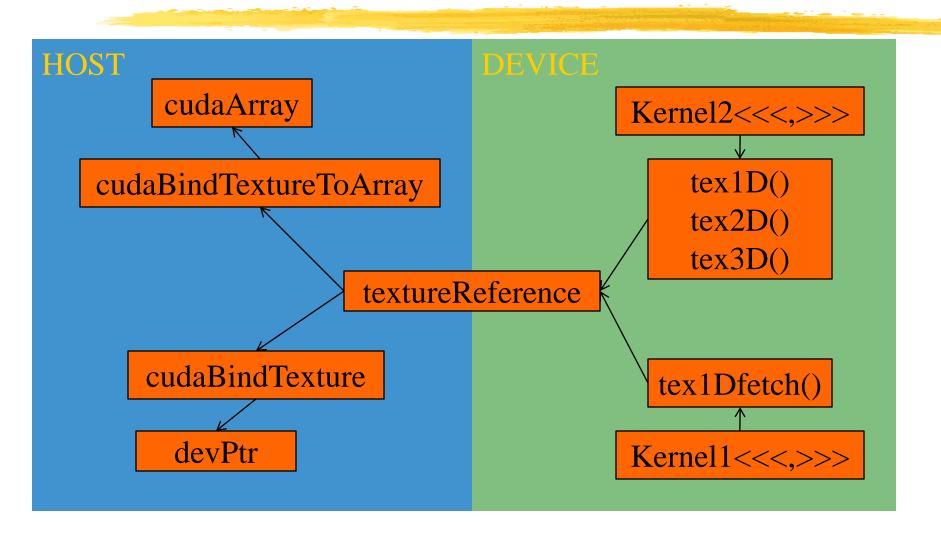
☑Исходный массив содержит данные в integer, возвращаемое значение во floating point представлении (доступный диапазон значений отображается в интервал [0, 1] или [-1,1])

#### cudaReadModeElementType

# Texture в CUDA (linear)

- **Ж**Можно использовать обычную *линейную* память
- ₩Ограничения:

  - Нет фильтрации
  - Доступ по целочисленным координтам
  - Обращение по адресу вне допустимого диапазона возвращает ноль



# Texture в CUDA (linear)

```
texture<float, 1, cudaReadModeElementType> q TexRef;
 global void kernel1 ( float * data )
  int idx = blockIdx.x * blockDim.x + threadIdx.x;
  data [idx] = tex1Dfetch(g TexRef, idx);
int main(int argc, char ** argv)
    float *phA = NULL, *phB = NULL, *pdA = NULL, *pdB = NULL;
    // -- memory allocation
    for (int idx = 0; idx < nThreads * nBlocks; idx++)
         phA[idx] = sinf(idx * 2.0f * PI / (nThreads * nBlocks) );
   CUDA SAFE CALL ( cudaMemcpy ( pdA, phA, nMemSizeInBytes, cudaMemcpyHostToDevice ) );
    CUDA SAFE CALL( cudaBindTexture(0, g TexRef, pdA, nMemSizeInBytes) );
    dim3 threads = dim3( nThreads );
    dim3 blocks = dim3( nBlocks );
    kernel1 <<<ble>blocks, threads>>> ( pdB );
    CUDA SAFE CALL( cudaThreadSynchronize() );
    CUDA SAFE CALL( cudaMemcpy ( phB, pdB, nMemSizeInBytes, cudaMemcpyDeviceToHost ) );
    // -- results check & memory release
    return 0;
```

# Texture в CUDA (cudaArray)

```
texture<float, 2, cudaReadModeElementType> g TexRef;
 global void kernel ( float * data )
   int idx = blockIdx.x * blockDim.x + threadIdx.x;
   data [idx + blockIdx.y * gridDim.x * blockDim.x] = tex2D(g TexRef, idx, blockIdx.y);
int main ( int argc, char * argv [] )
   cudaArray * paA = NULL;
                                                              // device cudaArray pointer
   // -- memory allocation
   cudaChannelFormatDesc cfDesc = cudaCreateChannelDesc(32, 0, 0, 0, cudaChannelFormatKindFloat);
   CUDA SAFE CALL( cudaMallocArray(&paA, &cfDesc, nBlocksX * nThreads, nBlocksY) );
   for (int idx = 0; idx < nThreads * nBlocksX; idx++) {</pre>
                                     = sinf(idx * 2.0f * PI / (nThreads * nBlocksX) );
       phA[idx]
       phA[idx + nThreads * nBlocksX] = cosf(idx * 2.0f * PI / (nThreads * nBlocksX) ); }
   CUDA SAFE CALL( cudaMemcpyToArray ( paA, 0, 0, phA, nMemSizeInBytes, cudaMemcpyHostToDevice ) );
   CUDA SAFE CALL( cudaBindTextureToArray(g TexRef, paA) );
   dim3 threads = dim3( nThreads );
   dim3 blocks = dim3( nBlocksX, nBlocksY );
   kernel2<<<ble>blocks, threads>>> ( pdB );
   CUDA SAFE CALL( cudaThreadSynchronize() );
   CUDA SAFE CALL ( cudaMemcpy ( phB, pdB, nMemSizeInBytes, cudaMemcpyDeviceToHost ) );
   // -- results check & memory release
   return 0;
```

# Свертка

- **ЖВ DSP свертка это один из основных** инструментов
- **Ж**Определение свертки:

$$r(i) = (s * k)(i) = \int s(i-n)k(n)dn$$

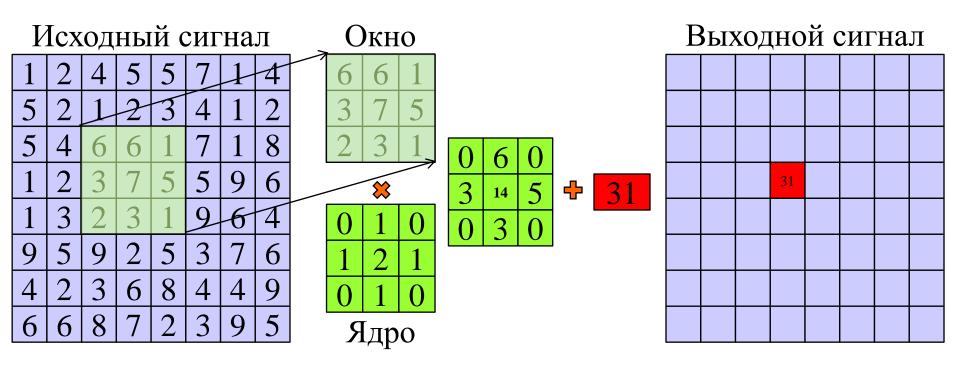
₩В Дискретном случае:

$$r(i) = (s * k)(i) = \sum s(i-n)k(n)$$

#B 2D для изображений:

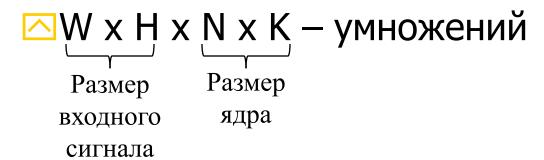
$$r(i, j) = (s * k)(i, j) = \sum_{n} \sum_{m} s(i - n, j - m)k(n, m)$$

# Свертка

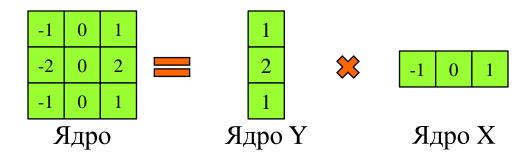


# Свертка

#### **ЖВычислительная сложность:**



## **ж**Сепарабельные фильтры



# Примеры

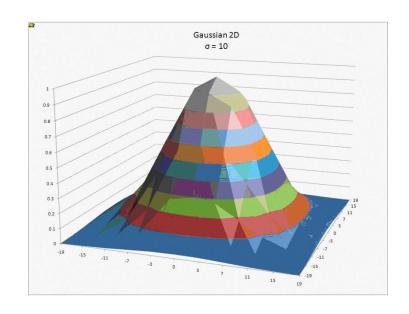
- **#Edge Detection**

### **Gaussian Blur**

# #Blur (размытие) изображение #Свертка с ядром:

$$k_{\sigma}(i) = \exp(-i^2/\sigma^2)$$

$$k_{\sigma}(i, j) = \exp(-(i^2 + j^2)/\sigma^2)$$



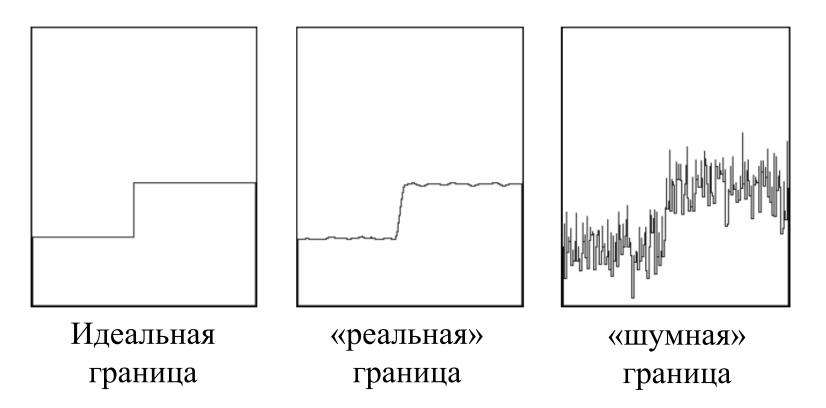
# **Gaussian Blur**

```
\#define SQR(x) ((x) * (x))
texture<float, 2, cudaReadModeElementType> g TexRef;
 global void GaussBlur( float * pFilteredImage, int W, int H, float r)
    int idx = blockIdx.x * blockDim.x + threadIdx.x;
    int idy = blockIdx.y * blockDim.y + threadIdx.y;
    float wSum = 0.0f;
    float rResult = 0.0f;
    for (int ix = -r; ix \le r; ix++)
        for (int iy = -r; iy \leq r; iy++)
        {
             float w = \exp(-(SQR(ix) + SQR(iy)) / SQR(r));
             rResult += w * tex2D(g TexRef, idx + ix, idy + iy);
             wSum += w;
     rResult = rResult / wSum;
    pFilteredImage[idx + idy * W] = rResult;
```

# Свертка: Вопрос Вам



# **Ж**Обнаружение границ – поиск разрывов в яркости изображения



# **Ж**Градиент функции f(x,y)

направление роста Определяется как  $\mathbf{G} = \left\{ \frac{\partial f}{\partial x} \frac{\partial f}{\partial y} \right\}$ 

$$|\mathbf{G}(\mathbf{x}, \mathbf{y})| = [G_x^2 + G_y^2]^{\frac{1}{2}}$$

$$\theta(\mathbf{x}, \mathbf{y}) = \tan^{-1}(G_y/G_x)$$

$$G_x$$

#### **ЖРазностная производная:**

$$\frac{\partial f(x,y)}{\partial x} \approx \frac{f(x+\Delta x,y)-f(x,y)}{\Delta x}$$

$$\frac{\partial f(x,y)}{\partial y} \approx \frac{f(x,y+\Delta y)-f(x,y)}{\Delta y}$$

ЖСвертка с ядром:

$$D_{1y} = \begin{bmatrix} -1 & 1 \end{bmatrix} \qquad D_{1y} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

#### **ЖРазностная** производная:

$$\frac{\partial f(x,y)}{\partial x} \approx \frac{f(x+\Delta x,y)-f(x-\Delta x,y)}{2\Delta x}$$

$$\frac{\partial f(x,y)}{\partial y} \approx \frac{f(x,y+\Delta y)-f(x,y-\Delta y)}{2\Delta y}$$
**ЖСвертка с ядром:**

$$D_{2y} = [-1 \ 0 \ 1] \qquad D_{2y} = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

#### **#Prewitt mask:**

$$P_{x} = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \quad P_{y} = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix}$$

#### **#Sobel mask:**

$$S_{x} = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} P_{y} = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

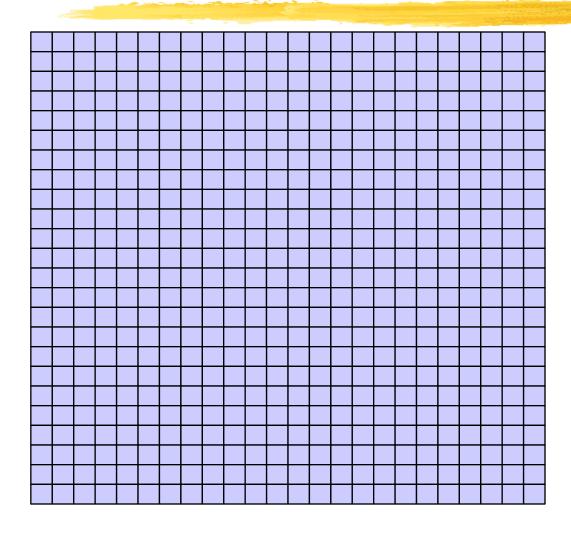
#### **Ж**Оператор Лапласа:

$$L[f(x,y)] = \frac{\partial^2 f(x,y)}{\partial x^2} + \frac{\partial^2 f(x,y)}{\partial y^2}$$

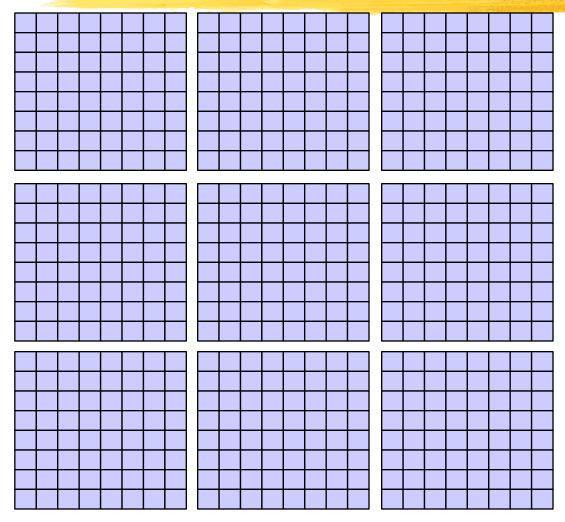
$$\frac{\partial^2 f(x,y)}{\partial x^2} \approx \frac{f(x+\Delta x,y) - 2f(x,y) + f(x-\Delta x,y)}{\Delta x^2}$$

$$\frac{\partial^2 f(x,y)}{\partial y^2} \approx \frac{f(x,y+\Delta y) - 2f(x,y) + f(x,y-\Delta y)}{\Delta y^2}$$

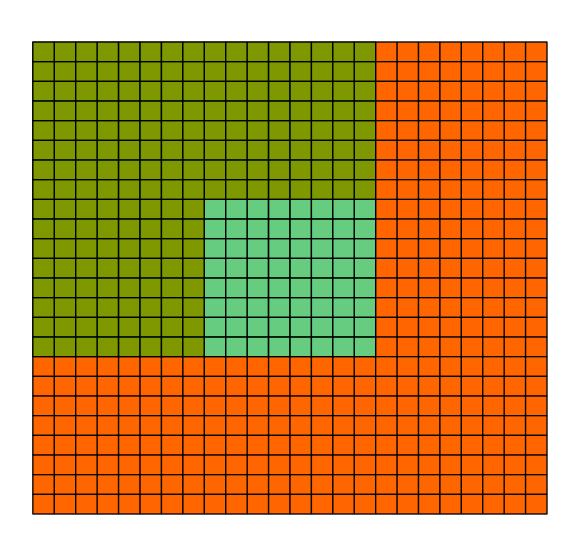
- **Ж**Использовать сепарабельные фильтры
  - Существенно меньше алгоритмическая сложность
- **Ж**Использовать *shared* память

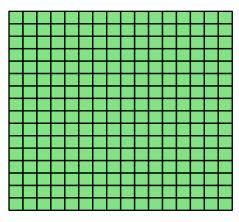


Исходное изображение

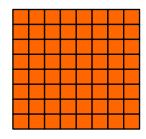


Исходное изображение



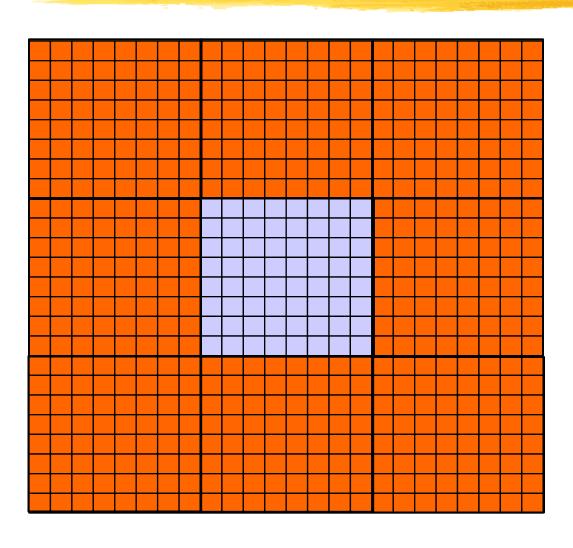


Ядро фильтра



«Фартук» фильтра

## Свертка Оптимизации



**Ж**Широко используется в ЦОС







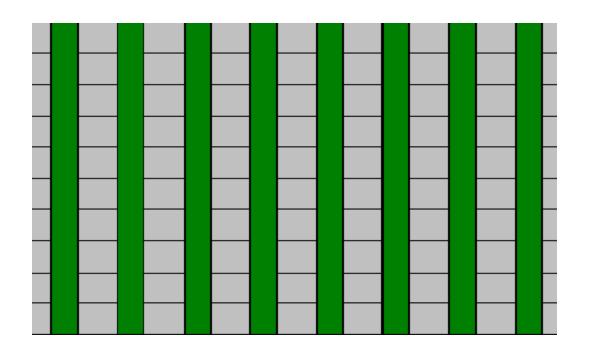
**ЖПредставитель семейства** пространственно-частотных 1D преобразований, задается формулами:

**ЖПрямое:** 
$$C(u) = \alpha(u) \sum_{x=0}^{N-1} f(x) \cos \left[ \frac{\pi(2x+1)u}{2N} \right], \quad u = 0,1,...,N-1$$
  
**ЖОбратное:**  $f(x) = \sum_{u=0}^{N-1} \alpha(u)C(u) \cos \left[ \frac{\pi(2x+1)u}{2N} \right], \quad x = 0,1,...,N-1$ 

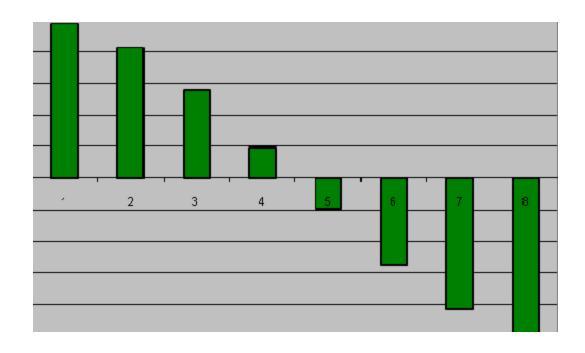
**Ж**Нормировочные коэффициенты:

$$\alpha(u) = \begin{cases} \sqrt{\frac{1}{N}}, u = 0\\ \sqrt{\frac{2}{N}}, u \neq 0 \end{cases}$$

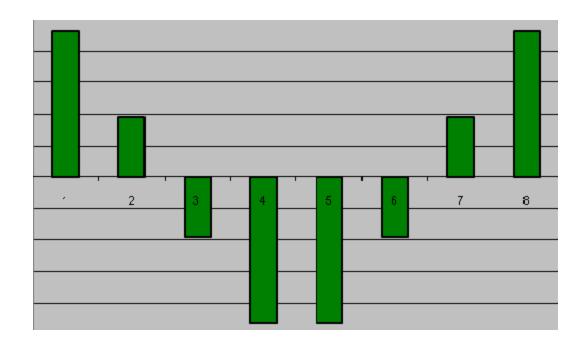
#8-точечный случай: u=0



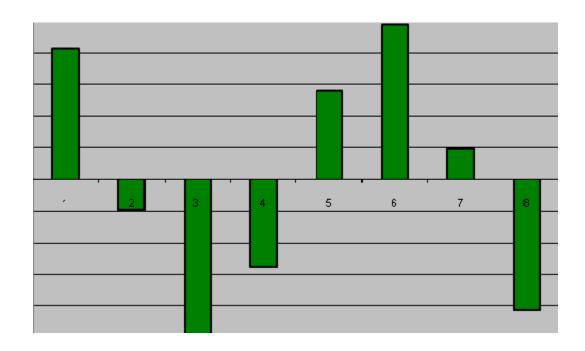
#8-точечный случай: u=1



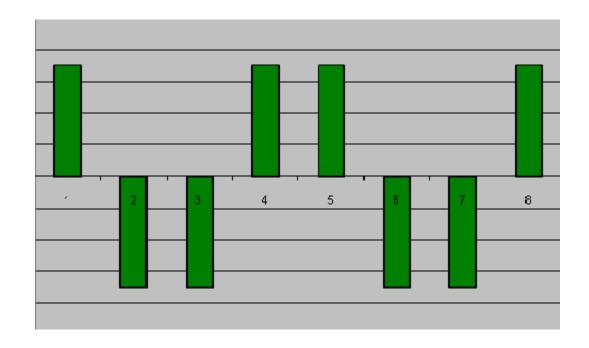
**%**8-точечный случай: *u*=2



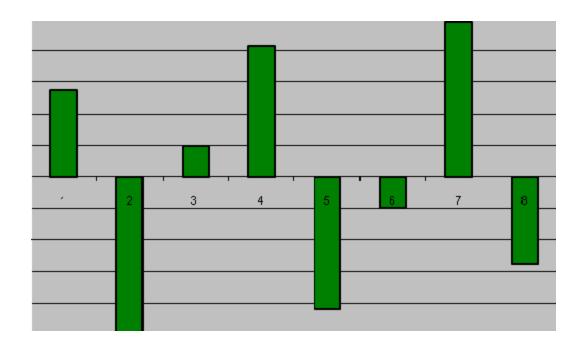
**Ж**8-точечный случай: *u*=*3* 



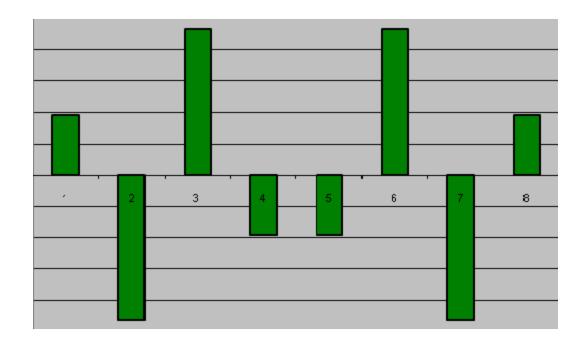
**Ж**8-точечный случай: *u*=4



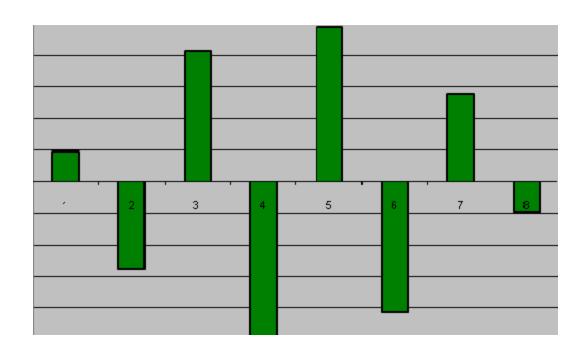
**¥**8-точечный случай: *u*=5



**¥**8-точечный случай: *u*=6



#8-точечный случай: u=7

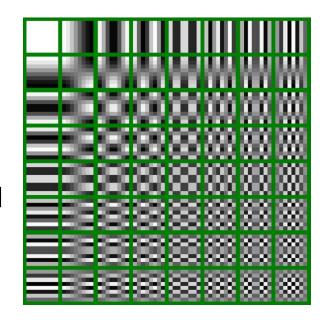


**Ж** N-мерное преобразование обладает свойством сепарабельности

$$C(u,v) = \alpha(u)\alpha(v) \sum_{x=0}^{N-1} \sum_{y=0}^{N-1} f(x,y) \cos \left[ \frac{\pi(2x+1)u}{2N} \right] \cos \left[ \frac{\pi(2y+1)v}{2N} \right]$$

- #2D-визуализация коэффициентов для случая 8x8 (изображение справа)
- ЖКоэффициенты *А[8x8]* преобразования вычисляются один раз

$$\mathcal{H}$$
  $C(u,v) = A^T XA$ 

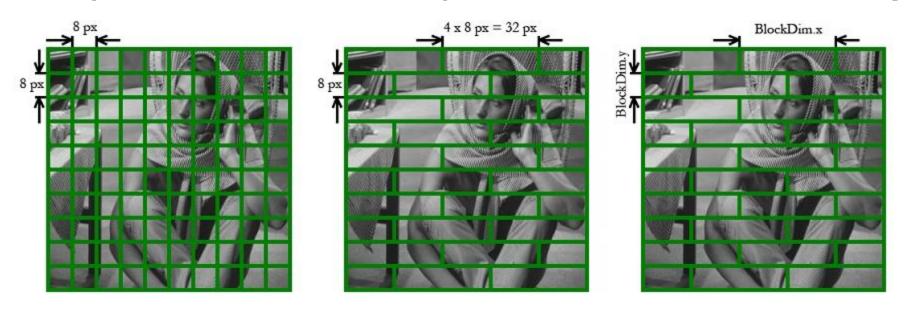


#### **ж**2 способа вычисления:

- Наивный, по формуле с предыдущего слайда (вычисление значения коэффициента путем подстановки индексов в формулу)
- С использованием сепарабельности
- △ Оба способа представлены в примере

- ∺Наивный: 64 нити на блок (8x8)
  - Загрузка одного пикселя из текстуры
  - Барьер
  - Вычисление линейной комбинации столбца threadIdx.y матрицы A (он же строка  $A^T$ ) со столбцом threadIdx.x матрицы A, запись
  - Барьер
  - Запись коэффициента в глобальную память

#Сепарабельный (блок обрабатывает несколько блоков 8x8, один тред обрабатывает вектор 8x1 или 1x8 целиком)



# Discrete Cosine Transform: Вопрос Вам



## Assignement #1 доступно

**#**Срок сдачи – следующий вторник

## Ресурсы нашего курса

#### **#CUDA.CS.MSU.SU**

- Место для вопросов и дискуссий
- Место для материалов нашего курса
- Место для ваших статей!
  - Если вы нашли какой-то интересный подход!
- ₩ www.steps3d.narod.ru
- ₩ www.nvidia.ru

# Вопросы

